

Mamba: Modelo SSM como alternativa a los Transformers

Mamba: SSM Model as an alternative to the transformers

Ana Beatriz Bestard Columbié¹, Daniela Elizabeth Cruz Morete², Lianet Soler Jay³

MsC. Yeisy Morete León⁴, Dr.C Dionis López Ramos⁵

¹ FITIB, Universidad de Oriente, cuba, ana.bestard@estudiantes.uo.edu.cu

² FITIB, Universidad de Oriente, cuba, daniela.cruz@estudiantes.uo.edu.cu

³ FITIB, Universidad de Oriente, cuba, lianet.soler@estudiantes.uo.edu.cu

⁴ Desoft, yeisy.morete@desoft.cu

^{5,3} FITIB, Universidad de Oriente, cuba, dionis@uo.edu.cu

Antecedentes: La inteligencia artificial ha avanzado notablemente desde la introducción de los Transformers en 2017, pero estos modelos enfrentan desafíos en eficiencia y escalabilidad. Mamba surge como una alternativa innovadora para superar estas limitaciones. Este informe analiza las restricciones de los Transformers, el desarrollo de Mamba y su impacto en la IA, proporcionando una visión clara de su relevancia y potencial en el procesamiento de secuencias de datos. La investigación abarca desde la presentación de Mamba el 1 de diciembre de 2023 hasta la actualidad. **Objetivos:** Evaluar la efectividad de Mamba como alternativa escalable y eficiente a los Transformers en el procesamiento de secuencias largas, impulsando su aplicación en inteligencia artificial a nivel nacional. Identificar las limitaciones de los Transformers en eficiencia y escalabilidad. Comparar el rendimiento de Mamba y Transformers en procesamiento de lenguaje y aprendizaje. Analizar las variantes de Mamba y su impacto en aplicaciones prácticas. **Resultados:** Análisis de la arquitectura Transformers y de sus limitaciones en el manejo de secuencias largas de datos. Complejidad computacional: La arquitectura Transformer usa autoatención para calcular relaciones entre tokens, lo que genera una complejidad computacional cuadrática. A medida que la secuencia crece, los cálculos aumentan exponencialmente, elevando el consumo de recursos y limitando la eficiencia en el procesamiento de secuencias largas debido a la carga computacional elevada durante la inferencia. Escalabilidad limitada: El crecimiento de los modelos Transformers dificulta su escalabilidad, ya que demandan altos recursos computacionales, elevando costos y tiempo. Algunos modelos de gran tamaño requieren inversiones millonarias en infraestructura, restringiendo su accesibilidad en entornos con recursos limitados. Arquitectura Mamba y sus resultados de rendimiento: La arquitectura de Mamba, basada en modelos de espacio de estados selectivos, optimiza el procesamiento de secuencias al emplear atención selectiva en lugar de autoatención cuadrática, reduciendo la complejidad computacional. Su mecanismo de atención jerárquico permite una escalabilidad lineal, superando las limitaciones de los Transformers. Además, sus modelos de espacio de estados bidireccionales capturan dependencias a largo plazo con mayor eficacia, mejorando la coherencia del contexto. Con 14,000 millones de parámetros, Mamba procesa 1,814


tokens por segundo, mientras que los Transformers pueden enfrentar errores de memoria.

MODEL	TOKEN.	PILE PPL ↓	LAMBADA PPL ↓	LAMBADA ACC ↑	HELLASWAG ACC ↑	PIQA ACC ↑	ARC-E ACC ↑	ARC-C ACC ↑	WINOGRANDE ACC ↑	AVERAGE ACC ↑
Hybrid H3-130M	GPT2	—	89.48	25.77	31.7	64.2	44.4	24.2	50.6	40.1
Pythia-160M	NeoX	29.64	38.10	33.0	30.2	61.4	43.2	24.1	51.9	40.6
→ Mamba-130M	NeoX	10.56	16.07	44.3	35.3	64.5	48.0	24.3	51.9	44.7
Hybrid H3-360M	GPT2	—	12.58	48.0	41.5	68.1	51.4	24.7	54.1	48.0
Pythia-410M	NeoX	9.95	10.84	51.4	40.6	66.9	52.1	24.6	53.8	48.2
→ Mamba-370M	NeoX	8.28	8.14	55.6	46.5	69.5	55.1	28.0	55.3	50.0
Pythia-1B	NeoX	7.82	7.92	56.1	47.2	70.7	57.0	27.1	53.5	51.9
→ Mamba-790M	NeoX	7.33	6.02	62.7	55.1	72.1	61.2	29.5	56.1	57.1
GPT-Neo 1.3B	GPT2	—	7.50	57.2	48.9	71.1	56.2	25.9	54.9	52.4
Hybrid H3-1.3B	GPT2	—	11.25	49.6	52.6	71.3	59.2	28.1	56.9	53.0
OPT-1.3B	OPT	—	6.64	58.0	53.7	72.4	56.7	29.6	59.5	55.0
Pythia-1.4B	NeoX	7.51	6.08	61.7	52.1	71.0	60.5	28.5	57.2	55.2
RWKV-1.5B	NeoX	7.70	7.04	56.4	52.5	72.4	60.5	29.4	54.6	54.3
→ Mamba-1.4B	NeoX	6.80	5.04	64.9	59.1	74.2	65.5	32.8	61.5	59.7
GPT-Neo 2.7B	GPT2	—	5.63	62.2	55.8	72.1	61.1	30.2	57.6	56.5
Hybrid H3-2.7B	GPT2	—	7.92	55.7	59.7	73.3	65.6	32.3	61.4	58.0
OPT-2.7B	OPT	—	5.12	63.6	60.6	74.8	60.8	31.3	61.0	58.7
Pythia-2.8B	NeoX	6.73	5.04	64.7	59.3	74.0	64.1	32.9	59.7	59.1
RWKV-3B	NeoX	7.00	5.24	63.9	59.6	73.7	67.8	33.1	59.6	59.6
→ Mamba-2.8B	NeoX	6.22	4.23	69.2	66.1	75.2	69.7	36.3	63.5	63.3
GPT-J-6B	GPT2	—	4.10	68.3	66.3	75.4	67.0	36.6	64.1	63.0
OPT-6.7B	OPT	—	4.25	67.7	67.2	76.3	65.6	34.9	65.5	62.9
Pythia-6.9B	NeoX	6.51	4.45	67.1	64.0	75.2	67.3	35.5	61.3	61.7
RWKV-7.4B	NeoX	6.31	4.38	67.2	65.5	76.1	67.8	37.5	61.0	62.5

Los resultados de Mamba muestran que su capa SSM selectiva recuerda tokens relevantes e ignora información irrelevante, resolviendo tareas con alta precisión. Además, generaliza a secuencias de un millón de tokens, 4000 veces más que en su entrenamiento, superando ampliamente otros métodos.

	MODEL	PARAMS	TEST ACCURACY (%) AT SEQUENCE LENGTH														
			2 ⁶	2 ⁷	2 ⁸	2 ⁹	2 ¹⁰	2 ¹¹	2 ¹²	2 ¹³	2 ¹⁴	2 ¹⁵	2 ¹⁶	2 ¹⁷	2 ¹⁸	2 ¹⁹	2 ²⁰
	MHA-Abs	137K	✓	99.6	100.0	58.6	26.6	18.8	9.8	10.9	7.8	✗	✗	✗	✗	✗	✗
	MHA-RoPE	137K	✓	✓	100.0	83.6	31.3	18.4	8.6	9.0	5.5	✗	✗	✗	✗	✗	✗
	MHA-xPos	137K	✓	✓	100.0	99.6	67.6	25.4	7.0	9.0	7.8	✗	✗	✗	✗	✗	✗
	H3	153K	✓	✓	100.0	80.9	39.5	23.8	14.8	8.2	5.9	6.6	8.2	4.7	8.2	6.3	7.4
	Hyena	69M*	97.7	✓	100.0	✓	44.1	12.5	6.6	5.1	7.0	5.9	6.6	6.6	5.9	6.3	9.8
→	Mamba	74K	✓	✓	100.0	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓

Mamba sobresale en el modelado de audio y la clasificación de secuencias de ADN, superando a modelos como SaShiMi y Hyena en calidad y métricas. Su capacidad para procesar hasta un millón de tokens lo hace ideal para el análisis de datos complejos. Además, escala mejor que HyenaDNA y Transformer++, logrando un rendimiento similar con 3 a 4 veces menos parámetros gracias a su mejora continua en perplexity a medida que aumenta su tamaño.



Evaluación del rendimiento de Mamba en comparación con los Transformers utilizando métricas estándar: Mamba, desarrollado por Albert Gu y Tri Dao, marca un avance significativo en IA frente a la arquitectura Transformer. Su robustez y superioridad en pruebas y benchmarks lo consolidan como una alternativa viable para procesar secuencias largas. Eficiencia computacional: Mamba utiliza modelos de espacio de estados selectivos (SSM) para gestionar la información de manera eficiente, superando a los Transformers que dependen de atención y múltiples capas. Su cálculo de atención en tiempo lineal, frente al cuadrático de los Transformers, le permite procesar entradas más grandes con mayor escalabilidad y eficiencia. Velocidad en generación de respuestas: Mamba es cinco veces más rápido que los Transformers en respuestas en tiempo real, ideal para atención al cliente. Su arquitectura optimizada mejora la eficiencia, superando a modelos de igual tamaño en evaluaciones y destacando en tareas cero-shot. Con 14,000 millones de parámetros, procesa 1,814 tokens por segundo, evitando errores de memoria. Escalabilidad y procesamiento de secuencias: Mamba es el primer modelo de secuencia lineal que iguala el rendimiento de un Transformer en perplexity y evaluaciones posteriores. Con escalabilidad de hasta 1B de parámetros, genera cinco veces más rápido que Transformers similares y supera modelos como HyenaDNA y Transformer++, logrando la misma perplexity con 3 a 4 veces menos parámetros. Investigación y desarrollo de variantes de Mamba: El desarrollo de variantes como Jamba, Mamba-2, VIM y Falcon Mamba 7B ha ampliado la aplicabilidad de Mamba, demostrando su robustez en diversas pruebas y benchmarks. Jamba, basado en Mamba, usa una arquitectura Mixture of Experts (MoE) que permite manejar hasta 256,000 tokens con una sola GPU de 80 GB, logrando un rendimiento tres veces superior a modelos como Llama 2 13B y Mixtral 8x7B.


Jamba outperforms or matches other models in its size class

Jamba scores the highest on reasoning related benchmarks.

	Reasoning				Aggregated assesment			
	HellaSwag	Arc Challenge	Winogrande	PIQA	MMLU	BBH	TruthfulQA	GSM8K (CoT)
Llama2 13B	80.7%	59.4%	72.8%	80.5%	54.8%	39.4%	37.4%	34.7%
Llama2 70B	85.3%	67.3%	80.2%	82.8%	69.8%	51.2%	44.9%	55.3%
Gemma 7B	81.2%	53.2%	72.3%	81.2%	64.3%	55.1%	44.8%	44.5%
Mixtral 8x7B	86.7%	66.0%	81.2%	83.0%	70.6%	50.3%	46.8%	60.4%
Jamba	87.1%	64.4%	82.5%	83.2%	67.4%	45.4%	46.4%	59.9%

Jamba 1.5 incluye Jamba-1.5-Large (94B) y Jamba-1.5-Mini (12B), optimizados para conversación y seguimiento de instrucciones. Gracias a la cuantización ExpertsInt8, Jamba-1.5-Large funciona en un solo nodo de 8 GPU sin perder rendimiento y con menor latencia. Ambos modelos superan a competidores de tamaño similar, con inferencia hasta 2.5 veces más rápida en contextos largos. Jamba-1.5-Mini es el más

rápido en contextos de 10K y el más potente en su categoría según Arena Hard.



Falcon Mamba y su rendimiento: Falcon Mamba supera las limitaciones de escala en modelos Mamba mediante una capa extra de normalización RMS, garantizando un entrenamiento estable en secuencias largas sin aumentar el uso de memoria. Mantiene una velocidad de generación constante y ha superado a modelos como Llama 3.1 8B y Mistral 7B en múltiples benchmarks, destacando por su eficacia e innovación.

Architecture	Model	IFEval	BBH	MATH Lvl 5	GPQA	MUSR	MMLU -PRO	Avg - 6 tasks
Mamba (SSLM)	Falcon Mamba 7B	33.36	19.88	3.63	8.05	10.86	14.47	15.04
Transformer	Mistral (7B)	22.66	24.04	2.64	5.59	8.36	21.7	14.17
	Llama 3.1 (8B)	12.7	25.29	4.61	6.15	8.98	24.95	13.78
	Falcon 2 (11B)	32.61	21.94	2.34	2.8	7.53	15.44	13.78

Resultados superiores del Performance de Falcon Mamba7b ante benchamrks de hugging face Leaderboard.

model name	ARC	HellaSwag	MMLU	Winogrande	TruthfulQA	GSM8K	Average
<i>Pure SSM models</i>							
Falcon Mamba-7B [*]	62.03	80.82	62.11	73.64	53.42	52.54	64.09
TRI-ML/mamba-7b-rw [*]	51.25	80.85	33.41	71.11	32.08	4.70	45.52
<i>Hybrid SSM-attention models</i>							
recurrentgemma-9b ^{**}	52.00	80.40	60.50	73.60	38.60	42.60	57.95
Zyphra/Zamba-7B-v1 [*]	56.14	82.23	58.11	79.87	52.88	30.78	60.00
<i>Transformer models</i>							
Falcon2-11B	59.73	82.91	58.37	78.30	52.56	53.83	64.28
Meta-Llama-3-8B	60.24	82.23	66.70	78.45	42.93	45.19	62.62
Meta-Llama-3.1-8B	58.53	82.13	66.43	74.35	44.29	47.92	62.28
Mistral-7B-v0.1	59.98	83.31	64.16	78.37	42.15	37.83	60.97
gemma-7B	61.09	82.20	64.56	79.01	44.79	50.87	63.75

Rendimiento de Falcon Mamba vs. Transformers en benchmarks.

Conclusiones: Mamba demuestra ser una alternativa escalable y eficiente a los Transformers en el procesamiento de secuencias largas, manteniendo un rendimiento constante de 1,814 tokens por segundo con 14,000M de parámetros, sin errores de memoria. Su comparación con Transformers en tareas específicas confirma su superioridad en eficiencia. Variantes como Jamba y Falcon Mamba refuerzan su versatilidad, destacando en contextos extensos. Su capacidad para optimizar procesamiento de lenguaje, secuencias de ADN y modelado de audio valida su impacto en aplicaciones de inteligencia artificial.